

Month 1 | 本地数仓筑基 + 业务分析能力

Week 1 | Olist 本地实验：Schema & Ingestion & Analysis

Day1 (5h)

- 0–30min：安装 / 打开 PostgreSQL + DBeaver/TablePlus，配置连接
- 30–90min：创建 `olist_raw` 模式，设计 `orders`、`order_payments` 字段结构
- 90–150min：手写 DDL，添加 PRIMARY KEY、NOT NULL、字段注释
- 150–240min：添加 CHECK 约束：`payment_value > 0`、`order_status` IN 合法值
- 240–300min：保存建表 SQL，测试执行，修复语法 / 逻辑错误

Day2 (5h)

- 0–60min：编写 `order_items`、`customers` 建表语句
- 60–120min：编写 `products`、`sellers` 建表语句
- 120–180min：编写 `order_reviews`、`geolocation` 建表语句
- 180–240min：统一字段命名、类型、注释规范
- 240–300min：整合成**一键建库 SQL**，完整执行无报错

Day3 (4.5h)

- 0–60min：为每张表构造 5 条合规测试数据
- 60–120min：执行 INSERT，验证正常入库逻辑
- 120–180min：构造违规数据：空主键、负金额、非法状态
- 180–270min：记录报错信息，总结约束作用，写实验笔记

Day4 (4.5h)

- 0–60min：学习 COPY 命令语法、CSV 格式要求
- 60–120min：导入 `orders` 前 1000 行，校验行数与主键
- 120–180min：导入 `order_payments` 前 1000 行
- 180–270min：对比手动插入与批量导入，记录注意事项

Day5 (4.5h)

- 0–60min：篡改 CSV：错误日期、空 `order_id`、负 `payment_value`
- 60–120min：尝试导入，观察失败拦截场景
- 120–180min：查询入库数据，识别残留脏数据
- 180–270min：编写清理语句，形成脏数据处理 SOP

Day6 (5h)

- 0–60min：按 `payment_type` 统计订单数、总金额、均价
- 60–120min：联表 `orders + payments`，调试关联逻辑
- 120–180min：筛选 `canceled` 订单，取支付金额 TOP10
- 180–240min：格式化 SQL，加注释，提高可读性
- 240–300min：校验结果一致性，保存最终脚本

Day7 (5h)

- 0-60min：用 CASE WHEN 划分 Budget/Regular/Premium
- 60-120min：统计各档位订单量、总金额
- 120-180min：计算各档位订单占比、金额占比
- 180-240min：归档本周全部 SQL，按模块分类
- 240-300min：写 1 页实验总结：学到什么、踩过什么坑

Week 2 | 全量入库 + 数据质量探查

Day1 (5h)

- 0-60min：整理 9 张 CSV 路径、编码、列名
- 60-150min：COPY 全量导入 olist_raw
- 150-240min：记录每张表行数，确认导入完整
- 240-300min：为 order_id/customer_id 建立索引

Day2 (4.5h)

- 0-60min：字段级 NULL 数量 & 缺失率统计
- 60-120min：主键重复检查，输出重复 ID
- 120-180min：order_status 分布统计
- 180-270min：输出结构化数据质量探查表

Day3 (4.5h)

- 0-60min：筛选 payment_value ≤ 0 异常记录
- 60-120min：检查时间乱序：发货 < 下单、签收 < 发货
- 120-180min：检查价格 / 运费极端异常值
- 180-270min：标记异常，计算整体异常率

Day4 (4.5h)

- 0-60min：统一字段命名：小写 + 下划线 + 英文语义
- 60-120min：统一时间、字符串、枚举格式
- 120-180min：为所有关键字段加英文注释
- 180-270min：输出数据字典表 (Data Dictionary)

Day5 (5h)

- 0-60min：删除完全损坏、无效行
- 60-120min：增加 is_abnormal 列标记异常订单
- 120-180min：修复空格、乱码、大小写问题
- 180-240min：校验清洗后数据分布合理性
- 240-300min：保存可重复执行的清洗 SQL

Day6 (4.5h)

- 0–60min：创建 `olist_clean` 模式
- 60–120min：创建清洗后标准表结构
- 120–180min：插入清洗后数据
- 180–270min：对比 `raw` 与 `clean` 行数差异

Day7 (5h)

- 0–60min：统计总订单、有效订单、GMV
 - 60–120min：州 / 城市订单分布、用户分布
 - 120–180min：支付方式占比、订单取消率
 - 180–240min：输出 **1 页英文业务简报**
 - 240–300min：本周成果归档
-

Week 3 | 复杂 SQL + 窗口函数 + 商业指标

Day1 (5h)

- 0–60min：计算下单→支付、支付→发货、发货→签收时长
- 60–120min：处理 `NULL` 与异常时长
- 120–180min：计算 `p25/p50/p75/p90` 时效分布
- 180–240min：整理可视化结果集
- 240–300min：生成物流时效宽表

Day2 (4.5h)

- 0–60min：按 `customer_unique_id` 统计订单频次
- 60–120min：计算用户复购率
- 120–180min：首次订单 vs 复购订单金额对比
- 180–270min：基础 `R/F/M` 指标统计

Day3 (5h)

- 0–60min：理解 `RANK/DENSE_RANK/ROW_NUMBER`
- 60–120min：各城市销售额 TOP10 商家
- 120–180min：各品类 GMV / 销量 TOP10 商品
- 180–240min：处理并列排名逻辑
- 240–300min：输出排名结果宽表

Day4 (4.5h)

- 0–60min：使用 `LAG()` 获取用户上一单时间
- 60–120min：计算用户订单间隔天数
- 120–180min：标记新客 / 复购 / 沉睡 / 流失
- 180–270min：生成用户行为特征表

Day5 (5h)

- 0–60min : 按日统计订单量、GMV
- 60–120min : 7 日移动平均 (SUM OVER)
- 120–180min : 日 / 周环比增长率
- 180–240min : 识别异常波动日期
- 240–300min : 生成时间趋势指标表

Day6 (4.5h)

- 0–60min : 设计全链路宽表字段
- 60–120min : `orders + items + products + payments` 联表
- 120–180min : 关联 `customers/sellers/geolocation`
- 180–270min : 校验金额、订单数一致性

Day7 (5h)

- 0–60min : 订单宽表
 - 60–120min : 用户宽表
 - 120–180min : 商品、商家、地区宽表
 - 180–240min : 品类、支付、评价宽表
 - 240–300min : 校验 8 张宽表主键与行数
-

Week 4 | Python ETL 脚本 + 自动化探查

Day1 (5h)

- 0–60min : 搭建 `venv`, 安装 `pandas`、`psycopg2`、`sqlalchemy`
- 60–120min : 编写数据库连接工具类
- 120–180min : 测试查询 → `DataFrame`
- 180–240min : 异常捕获、安全关闭连接
- 240–300min : 封装为 `db.py` 工具模块

Day2 (4.5h)

- 0–60min : CSV 读取函数, 处理编码异常
- 60–120min : 列名、字段、非空校验
- 120–180min : 基础清洗 : 去空格、统一大小写
- 180–270min : 编写入库函数, 支持全量 / 增量

Day3 (5h)

- 0–60min : 批量缺失值统计
- 60–120min : 重复行、重复主键检测
- 120–180min : 外键存在性检查
- 180–240min : 输出质量报告表格
- 240–300min : 记录问题数据清单

Day4 (4.5h)

- 0–60min : 实现 3σ 异常值检测函数
- 60–120min : 应用于金额、运费、价格
- 120–180min : 时间逻辑合法性校验
- 180–270min : 自动写入 `is_abnormal` 标记

Day5 (5h)

- 0–60min : 多表 Merge 逻辑, 处理一对多
- 60–120min : 构建用户宽表
- 120–180min : 构建订单宽表
- 180–240min : 缺失值填充策略
- 240–300min : 导出分析用宽表 CSV

Day6 (4.5h)

- 0–60min : 计算 R/F/M 分位数
- 60–120min : 定义用户分群规则
- 120–180min : 为每个用户打群体标签
- 180–270min : 统计各群体占比

Day7 (5h)

- 0–60min : 函数拆分, 单一职责重构
- 60–120min : 添加类型注解、docstring、英文注释
- 120–180min : 加入 logging 日志
- 180–240min : 配置外置, 避免硬编码
- 240–300min : 全脚本跑通, 形成可复用 ETL 包

Month 2 | GCP + dbt 现代数据建模

Week 5 | GCP + BigQuery + 三层结构

Day1 (5h)

- 0–60min : 注册 GCP、创建项目、开启计费提醒
- 60–120min : 熟悉 BigQuery、GCS 界面
- 120–180min : 创建 GCS Bucket
- 180–240min : 设置基本权限、安全策略
- 240–300min : 整理项目结构文档

Day2 (4.5h)

- 0–60min : 创建 `olist_raw` 数据集
- 60–120min : 创建 `olist_staging` 数据集
- 120–180min : 创建 `olist_mart` 数据集
- 180–270min : 设置命名规范、权限、地区

Day3 (5h)

- 0–60min : 上传 Olist CSV 到 GCS
- 60–120min : 创建 BQ 外部表
- 120–180min : 加载入 `olist_raw`
- 180–240min : 校验行数、字段完整性
- 240–300min : 记录加载日志

Day4 (4.5h)

- 0–60min : 学习分区表 (按日期分区)
- 60–120min : 对订单表建分区表
- 120–180min : 学习聚类键优化
- 180–270min : 为大表设置聚类

Day5 (5h)

- 0–60min : 普通表查询性能基准
- 60–120min : 分区表查询性能
- 120–180min : 聚类表查询性能
- 180–240min : 对比开销与速度
- 240–300min : 输出性能测试报告

Day6 (4.5h)

- 0–60min : 为所有表加英文注释
- 60–120min : 为关键字段加注释
- 120–180min : 规范命名、整理结构
- 180–270min : 权限最小化配置

Day7 (5h)

- 0–60min : 在 BQ 中跑基础探查 SQL
- 60–120min : 与本地 PostgreSQL 结果对齐
- 120–180min : 统计订单、GMV、用户数
- 180–240min : 记录差异原因
- 240–300min : 整理 BQ 常用 SQL 模板

Week 6 | dbt staging 标准化 + data test

Day1 (5h)

- 0–60min : 注册 dbt Cloud
- 60–120min : 连接 BigQuery
- 120–180min : 创建 dbt 项目
- 180–240min : 配置 `dbt_project.yml`
- 240–300min : 熟悉目录结构

Day2 (4.5h)

- 0–60min : 定义 `sources.yml`
- 60–120min : 学习 `source()`、`ref()`
- 120–180min : 学习 `materialized` 类型
- 180–270min : 测试最简单模型

Day3 (5h)

- 0–60min : 创建 `staging` 文件夹
- 60–120min : 编写 `stg_orders`
- 120–180min : 编写 `stg_payments`
- 180–240min : 字段重命名、类型标准化
- 240–300min : 统一注释格式

Day4 (4.5h)

- 0–60min : 为所有 `staging` 模型加 `unique` 测试
- 60–120min : 加 `not_null` 测试
- 120–180min : 运行 `dbt test`, 修复失败
- 180–270min : 完善测试覆盖率

Day5 (5h)

- 0–60min : 自定义测试 : `payment_value > 0`
- 60–120min : 时间逻辑合法性测试
- 120–180min : 外键引用有效性测试
- 180–240min : 运行全部测试
- 240–300min : 生成测试报告

Day6 (4.5h)

- 0–60min : 运行 `dbt docs generate`
- 60–120min : 查看文档站点
- 120–180min : 查看 `DAG` 血缘
- 180–270min : 优化模型可读性

Day7 (5h)

- 0–60min : 截图血缘图
 - 60–120min : 截图测试结果
 - 120–180min : 截图文档页面
 - 180–240min : 整理简历素材
 - 240–300min : 归档 `staging` 阶段成果
-

Week 7 | dbt 维度建模（星型模型）

Day1（4.5h）

- 0–60min：学习星型模型理论
- 60–120min：设计 `fact_orders`
- 120–180min：设计 `fact_order_items`
- 180–270min：画出模型关系图

Day2（5h）

- 0–60min：设计 `dim_customers`
- 60–120min：设计 `dim_products`
- 120–180min：设计 `dim_sellers`
- 180–240min：设计 `dim_geography`
- 240–300min：完成整体建模文档

Day3（4.5h）

- 0–60min：编写 `dim_customers` 模型
- 60–120min：加入基础 R/F/M 字段
- 120–180min：用户区域信息整合
- 180–270min：运行模型并校验

Day4（5h）

- 0–60min：构建 `dim_products`
- 60–120min：构建 `dim_sellers`
- 120–180min：类目翻译关联
- 180–240min：商家地区信息整合
- 240–300min：校验维度表完整性

Day5（4.5h）

- 0–60min：构建 `fact_orders`
- 60–120min：关联支付信息
- 120–180min：关联评价分数
- 180–270min：关联物流时效

Day6（5h）

- 0–60min：构建 `fact_order_items`
- 60–120min：关联商品、商家信息
- 120–180min：计算商品毛利、运费占比
- 180–240min：校验总金额一致性
- 240–300min：运行模型全量构建

Day7 (4.5h)

- 0–60min：总数核对：订单数、GMV、用户数
 - 60–120min：事实表与维度表关联测试
 - 120–180min：检查指标是否可正确计算
 - 180–270min：修复模型逻辑问题
-

Week 8 | dbt 增量 + 数据治理 + 文档

Day1 (5h)

- 0–60min：为每张表补充业务描述
- 60–120min：为关键字段写业务注释
- 120–180min：规范命名、统一口径
- 180–240min：更新 `schema.yml`
- 240–300min：生成完整文档

Day2 (4.5h)

- 0–60min：为维度表加完整性测试
- 60–120min：为事实表加准确性测试
- 120–180min：全量 `dbt test`
- 180–270min：修复所有失败用例

Day3 (5h)

- 0–60min：学习 `incremental` 模型
- 60–120min：将 `fact_orders` 改为增量
- 120–180min：设置 `unique_key`、`updated_at`
- 180–240min：测试全量 + 增量运行
- 240–300min：验证增量正确性

Day4 (4.5h)

- 0–60min：学习 `SCD Type 1` 逻辑
- 60–120min：对 `dim_customers` 实现覆盖更新
- 120–180min：测试更新逻辑
- 180–270min：固化 `SCD` 代码模板

Day5 (5h)

- 0–60min：重新生成 `dbt docs`
- 60–120min：检查完整血缘
- 120–180min：检查模型依赖关系
- 180–240min：优化 `DAG` 可读性
- 240–300min：截图最终数仓血缘

Day6 (4.5h)

- 0–60min : 撰写数仓架构说明
- 60–120min : 记录分层设计思路
- 120–180min : 记录指标口径
- 180–270min : 输出英文版设计文档

Day7 (5h)

- 0–60min : `dbt build` 全流程跑通
 - 60–120min : 校验最终指标
 - 120–180min : 确保可直接对接 BI
 - 180–240min : 整理 dbt 项目交付物
 - 240–300min : 本月项目复盘总结
-

Month 3 | Databricks + PySpark + Delta Lake

Week 9 | Databricks + PySpark 基础

Day1 (4.5h)

- 0–60min : 注册 Databricks 社区版
- 60–120min : 创建集群
- 120–180min : 熟悉 Notebook 环境
- 180–270min : 上传 Olist 数据

Day2 (5h)

- 0–60min : Spark DataFrame 基础
- 60–120min : `printSchema`、`show`、`count`
- 120–180min : `select`、`filter`、`withColumn`
- 180–240min : 简单聚合
- 240–300min : 基础练习全覆盖

Day3 (4.5h)

- 0–60min : 多表 Join 练习
- 60–120min : 分组聚合
- 120–180min : 排序、限制、去重
- 180–270min : 调试常见数据问题

Day4 (5h)

- 0–60min : 创建 Spark SQL 临时视图
- 60–120min : 跑订单、用户、商品核心指标
- 120–180min : 复现 BQ 业务指标
- 180–240min : 结果对齐校验
- 240–300min : 保存 SQL 笔记

Day5 (4.5h)

- 0–60min : 对比 Pandas 与 Spark
- 60–120min : 分区、懒加载、分布式执行
- 120–180min : 宽依赖、窄依赖
- 180–270min : 实操观察性能差异

Day6 (5h)

- 0–60min : 学习 `explain()`
- 60–120min : 查看物理计划
- 120–180min : 识别 Shuffle 点
- 180–240min : 分析简单查询计划
- 240–300min : 记录调优切入点

Day7 (4.5h)

- 0–60min : 理解 Job/Stage/Task
 - 60–120min : 观察 Spark UI
 - 120–180min : 识别执行瓶颈
 - 180–270min : 形成基础调优认知
-

Week 10 | Spark 性能调优

Day1 (5h)

- 0–60min : Shuffle 机制原理
- 60–120min : Shuffle 产生的场景
- 120–180min : Shuffle 对性能影响
- 180–240min : 实操观察 Shuffle 写入量
- 240–300min : 记录 Shuffle 优化思路

Day2 (4.5h)

- 0–60min : Broadcast Join 原理
- 60–120min : 识别小表与大表
- 120–180min : 开启广播关联
- 180–270min : 对比性能提升

Day3 (5h)

- 0–60min : 按 `seller_id/product_id` 观察倾斜
- 60–120min : 统计 key 分布
- 120–180min : 确认倾斜存在
- 180–240min : 记录倾斜特征
- 240–300min : 标记倾斜处理表

Day4 (4.5h)

- 0–60min : 学习加盐法 (Double Aggregation)
- 60–120min : 对倾斜 key 加盐
- 120–180min : 两阶段聚合
- 180–270min : 验证倾斜问题解决

Day5 (5h)

- 0–60min : repartition 使用场景
- 60–120min : coalesce 使用场景
- 120–180min : 控制分区数
- 180–240min : 避免小文件过多
- 240–300min : 分区数优化实验

Day6 (4.5h)

- 0–60min : cache()/persist() 原理
- 60–120min : 合适场景缓存
- 120–180min : 观察内存使用
- 180–270min : 避免滥用缓存

Day7 (5h)

- 0–60min : 基准性能测试
- 60–120min : 调优后性能测试
- 120–180min : 对比时间、IO、Shuffle
- 180–240min : 输出调优报告
- 240–300min : 整理调优模板

Week 11 | Delta Lake + Medallion 架构

Day1 (4.5h)

- 0–60min : Delta Lake 核心特性
- 60–120min : ACID、版本、Schema 约束
- 120–180min : 创建 Delta 表
- 180–270min : 基础读写测试

Day2 (5h)

- 0–60min : Medallion 三层架构
- 60–120min : 创建 Bronze 层 (原始数据)
- 120–180min : 创建 Silver 层 (清洗)
- 180–240min : 创建 Gold 层 (指标)
- 240–300min : 画出分层架构图

Day3 (4.5h)

- 0–60min : 写入 Delta 表
- 60–120min : 按日期分区
- 120–180min : 优化文件大小
- 180–270min : 检查数据完整性

Day4 (5h)

- 0–60min : 学习 MERGE INTO
- 60–120min : 实现增量 Upsert
- 120–180min : 测试新增、更新逻辑
- 180–240min : 校验历史数据不变
- 240–300min : 固化 Upsert 模板

Day5 (4.5h)

- 0–60min : 查看版本历史
- 60–120min : VERSION AS OF 回溯
- 120–180min : 恢复误删 / 误改数据
- 180–270min : 记录时间旅行用法

Day6 (5h)

- 0–60min : VACUUM 清理旧版本
- 60–120min : 设置保留时间
- 120–180min : 避免误删可用版本
- 180–240min : 优化存储成本
- 240–300min : 验证清理后正常读写

Day7 (4.5h)

- 0–60min : 全量跑通 Bronze → Silver → Gold
- 60–120min : 校验各层指标
- 120–180min : 形成标准湖仓流程
- 180–270min : 输出湖仓交付文档

Week 12 | Spark Streaming 实时监控

Day1 (5h)

- 0–60min : Streaming 基础概念
- 60–120min : 模拟流式订单数据生成
- 120–180min : 按秒 / 分钟生成微批次
- 180–240min : 保存为流式数据源
- 240–300min : 测试数据生成逻辑

Day2 (4.5h)

- 0–60min : 创建 Streaming 读取
- 60–120min : 定义 Schema
- 120–180min : 流式解析与过滤
- 180–270min : 观察微批次触发

Day3 (5h)

- 0–60min : Watermark 作用
- 60–120min : 设置允许延迟时间
- 120–180min : 处理乱序数据
- 180–240min : 避免中间状态膨胀
- 240–300min : 调试水位线逻辑

Day4 (4.5h)

- 0–60min : 按分钟窗口聚合
- 60–120min : 统计分钟级订单量
- 120–180min : 统计分钟级 GMV
- 180–270min : 输出实时指标

Day5 (5h)

- 0–60min : 将流结果写入 Delta Gold
- 60–120min : 设置输出模式
- 120–180min : 检查写入稳定性
- 180–240min : 断点续跑测试
- 240–300min : 形成实时表

Day6 (4.5h)

- 0–60min : 查询实时指标表
- 60–120min : 观察最新窗口数据
- 120–180min : 模拟延迟数据重算
- 180–270min : 验证结果正确性

Day7 (5h)

- 0–60min : 完整实时 Pipeline 跑通
- 60–120min : 录制实时指标变化
- 120–180min : 整理实时项目说明
- 180–240min : 输出架构图
- 240–300min : 本月大数据模块复盘

Month 4 | 工程化全链路 (Airflow + Terraform + CI/CD)

Week 13 | Docker + 模块化脚本

Day1 (4.5h)

- 0–60min : Docker 核心概念
- 60–120min : 安装 Docker
- 120–180min : 测试 hello-world
- 180–270min : 学习镜像 / 容器 / 仓库

Day2 (5h)

- 0–60min : 编写 Dockerfile 基础结构
- 60–120min : 基于 Python 镜像
- 120–180min : 复制代码、安装依赖
- 180–240min : 设置启动命令
- 240–300min : 测试基础镜像构建

Day3 (4.5h)

- 0–60min : `docker build` 构建
- 60–120min : `docker run` 运行
- 120–180min : 查看日志
- 180–270min : 进入容器调试

Day4 (5h)

- 0–60min : 编写 `.dockerignore`
- 60–120min : 多阶段构建
- 120–180min : 减小镜像体积
- 180–240min : 对比优化前后大小
- 240–300min : 保存最终 Dockerfile

Day5 (4.5h)

- 0–60min : 模块化 ETL 函数
- 60–120min : 抽离公共工具
- 120–180min : 配置与代码分离
- 180–270min : 形成可复用模板

Day6 (5h)

- 0–60min : 将 Olist ETL 移入镜像
- 60–120min : 挂载配置 / 数据目录
- 120–180min : 容器内完整跑批
- 180–240min : 校验入库结果
- 240–300min : 记录容器化步骤

Day7 (4.5h)

- 0–60min：制作通用 ETL 模板
 - 60–120min：注释、参数化、易用性
 - 120–180min：编写使用说明
 - 180–270min：归档 Docker 项目
-

Week 14 | Airflow 调度

Day1 (5h)

- 0–60min：Airflow 核心概念
- 60–120min：DAG/Task/Operator
- 120–180min：安装 / 启动环境
- 180–240min：登录 UI
- 240–300min：熟悉界面

Day2 (4.5h)

- 0–60min：创建第一个 DAG
- 60–120min：PythonOperator 执行 BQ 查询
- 120–180min：设置 schedule
- 180–270min：测试手动触发

Day3 (5h)

- 0–60min：设置任务依赖
- 60–120min：构建线性依赖 DAG
- 120–180min：观察执行顺序
- 180–240min：处理失败重试
- 240–300min：调试依赖逻辑

Day4 (4.5h)

- 0–60min：设置重试次数、间隔
- 60–120min：设置任务超时
- 120–180min：配置邮件告警
- 180–270min：测试失败告警

Day5 (5h)

- 0–60min：幂等性设计原则
- 60–120min：按日期分区避免重复
- 120–180min：支持重跑、补跑
- 180–240min：测试多次执行一致性
- 240–300min：形成幂等性规范

Day6 (4.5h)

- 0–60min : 使用 `BashOperator` 触发 `dbt`
- 60–120min : 编写 `dbt run` 任务
- 120–180min : 编写 `dbt test` 任务
- 180–270min : 测试 `Airflow + dbt` 联动

Day7 (5h)

- 0–60min : 设计完整 ETL 调度 DAG
 - 60–120min : `Spark` 任务 → `BQ` → `dbt`
 - 120–180min : 设置依赖与告警
 - 180–240min : 全流程调度测试
 - 240–300min : 输出稳定版 DAG
-

Week 15 | Terraform + IaC + CI/CD

Day1 (4.5h)

- 0–60min : Terraform 基础语法
- 60–120min : 学习 HCL
- 120–180min : `provider` 配置
- 180–270min : 初始化项目

Day2 (5h)

- 0–60min : 定义 `GCS Bucket` 资源
- 60–120min : 定义 `BigQuery` 数据集
- 120–180min : 设置命名、位置、权限
- 180–240min : 格式化与校验
- 240–300min : 整理资源文件

Day3 (4.5h)

- 0–60min : `terraform init`
- 60–120min : `terraform plan`
- 120–180min : `terraform apply`
- 180–270min : `terraform destroy` 测试

Day4 (5h)

- 0–60min : 学习 `backend` 配置
- 60–120min : 使用 `GCS` 存储 `tfstate`
- 120–180min : 状态锁、安全共享
- 180–240min : 迁移本地状态到远端
- 240–300min : 验证多人协作安全

Day5 (4.5h)

- 0–60min：模块化思想
- 60–120min：抽取 GCS 模块
- 120–180min：抽取 BQ 模块
- 180–270min：参数化调用模块

Day6 (5h)

- 0–60min：一键创建完整环境
- 60–120min：一键销毁环境
- 120–180min：成本控制检查
- 180–240min：权限最小化检查
- 240–300min：输出 IaC 文档

Day7 (4.5h)

- 0–60min：CI/CD 基本思路
 - 60–120min：GitHub Actions 基础
 - 120–180min：自动化 plan /apply 思路
 - 180–270min：编写简单流水线示例
-

Week 16 | 全链路闭环 + 面试交付

Day1 (5h)

- 0–60min：绘制整体架构图
- 60–120min：GCS → Spark → BQ → dbt → BI
- 120–180min：明确每一层职责
- 180–240min：确定数据流与调度时序
- 240–300min：输出架构设计文档

Day2 (4.5h)

- 0–60min：在 Airflow 中加入 Spark 任务
- 60–120min：调试 Spark 提交命令
- 120–180min：确保成功写入 BQ
- 180–270min：测试链路稳定性

Day3 (5h)

- 0–60min：Airflow 触发 dbt test
- 60–120min：测试通过才继续
- 120–180min：触发 dbt build
- 180–240min：校验最终指标产出
- 240–300min：全流程自动化跑通

Day4 (4.5h)

- 0–60min：设计数据质量门禁
- 60–120min：测试失败则中断 pipeline
- 120–180min：告警通知
- 180–270min：模拟数据异常场景

Day5 (5h)

- 0–60min：端到端全流程测试
- 60–120min：日志、监控、告警检查
- 120–180min：指标一致性校验
- 180–240min：修复最后细节问题
- 240–300min：形成稳定生产级 Demo

Day6 (4.5h)

- 0–60min：录制项目演示视频
- 60–120min：截图架构图、血缘图
- 120–180min：截图测试报告、文档
- 180–270min：整理可视化素材

Day7 (5h)

- 0–60min：撰写英文简历项目描述
- 60–120min：准备 1 分钟自我介绍版
- 120–180min：准备 3 分钟技术详述版
- 180–240min：整理高频面试问答
- 240–300min：完整项目归档, Ready for Interview

Month 1 | 本地数仓筑基 + 业务分析能力

Week 1 | SQL 建表 & 数据导入

每日知识点

- Day1 : PostgreSQL 连接、Schema、DDL、主键、非空、CHECK 约束
- Day2 : 多表 DDL 设计、字段规范、数据字典、一键建库脚本
- Day3 : INSERT 测试数据、约束校验、异常报错分析
- Day4 : COPY 批量导入、CSV 格式、数据校验
- Day5 : 脏数据构造、导入失败场景、数据清洗基础
- Day6 : 分组统计、多表 JOIN、TOP N 分析
- Day7 : CASE WHEN 分箱、占比计算、SQL 归档

每周复盘技能

- 手写建表 SQL，设计合理表结构
- 批量导入数据并做基础校验
- 识别并处理脏数据
- 基础业务指标 SQL

合格标准

- 9 张表 DDL 可一键执行无报错
 - 能导入数据并查出基本业务统计
 - 能解释每个约束的作用
-

Week 2 | 全量数据 & 质量探查

每日知识点

- Day1 : 全量 COPY 导入、索引建立
- Day2 : NULL 探查、主键重复、字段分布
- Day3 : 异常值识别、时间逻辑校验
- Day4 : 命名规范、字段注释、数据字典
- Day5 : 数据清洗、标记异常、修复格式
- Day6 : olits_clean 层构建、数据对比
- Day7 : 业务简报、订单 / GMV / 地区分布

每周复盘技能

- 全流程数据探查能力
- 数据质量问题定位
- 分层建表思想 (raw → clean)
- 输出业务概览指标

合格标准

- 有完整质量报告

- 有干净的 clean 层
 - 能说出数据有哪些问题、怎么处理
-

Week 3 | 高级 SQL & 商业指标

每日知识点

- Day1：订单时效计算、分位数
- Day2：复购率、RFM 基础
- Day3：窗口函数 RANK/DENSE_RANK
- Day4：LAG () 间隔计算、用户分层
- Day5：时间序列、移动平均、环比
- Day6：全链路宽表 JOIN
- Day7：8 张业务宽表构建

每周复盘技能

- 熟练使用窗口函数
- 能做用户行为 / 商品 / 商家分析
- 构建大宽表支撑 BI

合格标准

- 能独立写出复杂分析 SQL
 - 8 张宽表可正常查询、结果一致
-

Week 4 | Python ETL 模块化

每日知识点

- Day1：psycopg2、SQLAlchemy、数据库工具类
- Day2：CSV 读取、校验、清洗、入库
- Day3：缺失 / 重复 / 外键质量检查
- Day4：3 σ 异常检测、时间校验
- Day5：Pandas Merge、宽表构建
- Day6：RFM 分群、用户标签
- Day7：模块化、注解、日志、配置分离

每周复盘技能

- 编写自动化 ETL 脚本
- 数据质量自动化检查
- 代码工程化（函数、模块、日志）

合格标准

- 一套可重复运行的 ETL 工具
- 能自动输出质量报告
- 代码结构清晰、可维护

Month 2 | GCP + dbt 现代数据建模

Week 5 | GCP + BigQuery 三层架构

每日知识点

- Day1 : GCP 项目、GCS、BQ 入门
- Day2 : BQ 数据集 (raw/staging/mart)
- Day3 : GCS → BQ 数据加载
- Day4 : 分区表、聚类表
- Day5 : 性能对比、成本观察
- Day6 : 注释规范、权限
- Day7 : BQ 与本地 SQL 结果对齐

每周复盘技能

- 云上数据平台搭建
- 分区 / 聚类优化
- 数仓分层思想

合格标准

- BQ 三层结构建好
 - 数据加载正常、性能有提升
-

Week 6 | dbt staging + test

每日知识点

- Day1 : dbt Cloud 项目搭建
- Day2 : source/ref/materialized
- Day3 : staging 模型标准化
- Day4 : unique/not_null 测试
- Day5 : 自定义测试 (金额 > 0、时间合法)
- Day6 : dbt docs 与血缘
- Day7 : 简历素材截图归档

每周复盘技能

- dbt 基础使用
- 数据测试体系
- 数仓血缘理解

合格标准

- staging 层跑完
 - 所有 test 通过
 - 能看懂 DAG 血缘
-

Week 7 | dbt 星型建模

每日知识点

- Day1 : fact 表设计
- Day2 : dim 表设计
- Day3 : dim_customers (含 RFM)
- Day4 : dim_products / dim_sellers
- Day5 : fact_orders
- Day6 : fact_order_items
- Day7 : 模型一致性校验

每周复盘技能

- 星型模型设计
- 事实表 + 维度表建设
- 指标口径对齐

合格标准

- 一套完整数仓模型
 - 订单数 / GMV 可正确统计
-

Week 8 | dbt 增量 + SCD + 治理

每日知识点

- Day1 : 业务注释完善
- Day2 : 全量测试覆盖
- Day3 : incremental 增量模型
- Day4 : SCD Type 1
- Day5 : dbt docs + lineage
- Day6 : 数仓设计文档
- Day7 : dbt build 全流程

每周复盘技能

- 增量同步
- 缓慢变化维处理
- 数据治理意识

合格标准

- 增量运行正常
 - SCD 逻辑正确
 - 项目可直接对接 BI
-

Month 3 | Databricks + PySpark + Delta Lake

Week 9 | PySpark 基础

每日知识点

- Day1 : Databricks 集群
- Day2 : DataFrame 基础操作
- Day3 : Join / 聚合
- Day4 : Spark SQL 复现指标
- Day5 : Pandas $\rightleftharpoons$ Spark 区别
- Day6 : explain () 执行计划
- Day7 : Job/Stage/Task 理解

每周复盘技能

- PySpark 数据处理
- 看懂简单执行计划

合格标准

- 能用 Spark 算出 BQ 一致指标
-

Week 10 | Spark 调优

每日知识点

- Day1 : Shuffle 机制
- Day2 : Broadcast Join
- Day3 : 数据倾斜识别
- Day4 : 加盐法解决倾斜
- Day5 : repartition/coalesce
- Day6 : cache/persist
- Day7 : 调优报告

每周复盘技能

- 定位性能瓶颈
- 倾斜处理
- 分区优化

合格标准

- 能说出为什么慢、怎么优化
-

Week 11 | Delta Lake + 三层湖仓

每日知识点

- Day1 : Delta ACID、版本
- Day2 : Bronze/Silver/Gold

- Day3 : Delta 分区写入
- Day4 : MERGE INTO Upsert
- Day5 : 时间旅行
- Day6 : VACUUM 清理
- Day7 : 湖仓闭环

每周复盘技能

- 湖仓架构搭建
- 增量 Upsert
- 快照与回滚

合格标准

- 三层结构可跑通
 - MERGE 正确更新
-

Week 12 | Spark Streaming 实时

每日知识点

- Day1 : 模拟流数据
- Day2 : 流读取
- Day3 : Watermark 乱序处理
- Day4 : 窗口聚合 (订单 / GMV)
- Day5 : 写入 Gold Delta
- Day6 : 实时指标查询
- Day7 : 实时 pipeline 闭环

每周复盘技能

- 准实时数据开发
- 窗口计算
- 乱序处理

合格标准

- 能按分钟产出实时指标
-

Month 4 | 工程化全链路

Week 13 | Docker 容器化

每日知识点

- Day1 : Docker 基础
- Day2 : Dockerfile 编写
- Day3 : build/run/logs
- Day4 : .dockerignore、多阶段构建

- Day5 : ETL 模块化
- Day6 : 容器跑 ETL
- Day7 : 模板化

每周复盘技能

- 代码容器化
- 环境一致性

合格标准

- 一个镜像可直接跑 ETL
-

Week 14 | Airflow 调度

每日知识点

- Day1 : Airflow 架构
- Day2 : 第一个 DAG
- Day3 : 任务依赖
- Day4 : 重试 / 超时 / 告警
- Day5 : 幂等性设计
- Day6 : Airflow + dbt
- Day7 : 全流程调度

每周复盘技能

- 批调度开发
- 数据 pipeline 编排

合格标准

- 一天完整 ETL 可自动调度
-

Week 15 | Terraform IaC + CI/CD

每日知识点

- Day1 : Terraform 语法
- Day2 : GCS + BQ 资源定义
- Day3 : plan/apply/destroy
- Day4 : GCS 远端 state
- Day5 : 模块化
- Day6 : 一键环境
- Day7 : CI/CD 思路

每周复盘技能

- 基础设施即代码
- 环境自动化搭建

合格标准

- 一行命令创建 / 销毁整个数据平台
-

Week 16 | 全链路闭环 + 面试

每日知识点

- Day1：整体架构设计
- Day2：Airflow 调度 Spark
- Day3：Airflow + dbt 全链路
- Day4：数据质量门禁
- Day5：端到端测试
- Day6：演示素材录制
- Day7：英文简历 + 面试口述稿

每周复盘技能

- 全栈数据工程 pipeline
- 项目表达与面试呈现

合格标准

- 一套可演示、可讲、可面试的完整项目