

原始层数据脏数据处理标准操作规程（SOP）

1. 目的

规范原始层（olist_raw schema）数据脏数据的识别、检查、清理及验证流程，确保数据清洗过程可追溯、可复用、标准化，杜绝脏数据流入核心层，保障数据质量，为后续数据建模、分析及应用提供可靠的数据支撑。

2. 适用范围

本规程适用于olist_raw schema下所有数据表（包括但不限于orders、order_payments、order_items等）的脏数据处理工作，涵盖数据导入后、核心层入库前的全量脏数据排查与清理，涉及所有相关操作人员（数据处理员、实验人员）。

3. 术语与定义

- 原始层（RAW层）**：用于存储未经处理的源数据（如CSV导入数据），无强制约束，仅用于数据落地与备份的基础数据层。
- 脏数据**：不符合业务规则、数据规范，无法直接用于分析或建模的数据，本场景核心包括：主键为NULL、主键重复、关键字段空字符串（''）、业务时间逻辑异常、外键无关联（孤儿数据）。
- 数据校验**：脏数据清理完成后，对数据质量进行二次检查，确认脏数据已全部处理，数据符合规范。

4. 职责分工

- 数据处理员**：负责执行脏数据检查、清理操作，记录处理过程及结果，完成校验并提交报告。
- 复核人员**：负责审核脏数据处理结果，确认清理流程合规、数据质量达标，确保无遗漏、无误操作。

5. 脏数据处理流程（核心步骤）

5.1 前置准备

- 确认原始层数据表已完成数据导入（如通过COPY、\copy命令导入CSV数据）。
- 准备脏数据检查SQL脚本、清理SQL脚本，确保脚本可直接运行，对应目标数据表。
- 备份原始数据（可选，建议执行），避免清理操作失误导致数据丢失，备份命令：CREATE TABLE 表名_backup AS SELECT * FROM 表名;

5.2 脏数据检查（必做步骤）

按以下顺序执行检查，逐一排查各类脏数据，记录每类脏数据的数量、具体异常信息，填写《脏数据检查记录表》。

1. 主键非空检查：查询主键字段为NULL的记录，确认数量及分布。

```
-- 以orders表order_id主键为例
SELECT COUNT(*) AS null_pk_count
FROM olist_raw.orders
WHERE order_id IS NULL;
```

2. 主键唯一性检查：查询主键重复的记录，确认重复主键及重复次数。

```
-- 以orders表order_id主键为例
SELECT order_id, COUNT(*) AS repeat_count
FROM olist_raw.orders
GROUP BY order_id
HAVING COUNT(*) > 1;
```

3. 空字符串检查：查询关键字段（如主键、业务核心字段）为空字符串（''）的记录，区分空字符串与NULL。

```
-- 以orders表order_id为例
SELECT COUNT(*) AS empty_string_count
FROM olist_raw.orders
WHERE order_id = '';
```

4. 业务时间逻辑异常检查：查询时间字段不符合业务逻辑的记录（如购买时间晚于审核时间、审核时间晚于发货时间）。

```
-- 以orders表时间字段为例
SELECT *
FROM olist_raw.orders
WHERE order_purchase_timestamp > order_approved_at
      OR order_approved_at > order_delivered_carrier_date;
```

5. 外键关联完整性检查：查询外键字段无对应主表数据的孤儿记录（如支付记录的order_id在订单表中不存在）。

```
-- 以order_payments表与orders表关联为例
SELECT op.*
FROM olist_raw.order_payments op
LEFT JOIN olist_raw.orders o
ON op.order_id = o.order_id
WHERE o.order_id IS NULL;
```

5.3 脏数据确认与记录

1. 将每类脏数据的检查结果（数量、异常内容）详细记录到《脏数据检查记录表》，明确脏数据类型、涉及数据表、异常条数。
2. 若脏数据数量较大（如超过总数据量的5%），需上报负责人，确认清理方案后再执行后续操作；若数量较少，可直接按标准规则清理。

5.4 脏数据清理（核心操作）

遵循“先查询、后清理，可修复则修复，不可修复则删除”的原则，按以下规则执行清理操作，每执行一条清理脚本，记录操作内容、执行时间、影响条数。

1. 主键NULL清理：直接删除主键为NULL的记录（无法修复，不符合主键非空规则）。

```
DELETE FROM olist_raw.orders
WHERE order_id IS NULL;
```

2. 主键重复清理：保留重复主键中最早插入的一条（按ctid排序），删除其余重复记录。

```
DELETE FROM olist_raw.orders
WHERE ctid NOT IN (
    SELECT MIN(ctid)
    FROM olist_raw.orders
    GROUP BY order_id
);
```

3. 空字符串清理：删除关键字段为空字符串的记录（业务上非法，无法修复）。

```
DELETE FROM olist_raw.orders
WHERE order_id = '';
```

4. 时间逻辑异常清理：删除时间不符合业务逻辑的记录（无法修复，影响后续分析）。

```
DELETE FROM olist_raw.orders
WHERE order_purchase_timestamp > order_approved_at;
```

5. 孤儿数据清理：删除外键无关联的记录（无对应主表数据，无业务意义）。

```
DELETE FROM olist_raw.order_payments op
USING olist_raw.orders o
WHERE op.order_id = o.order_id
AND o.order_id IS NULL;
```

5.5 清理后校验

清理完成后，重复执行“5.2 脏数据检查”的所有SQL脚本，确认以下结果，填写《脏数据清理校验记录表》：

- 主键NULL数量为0；
- 无主键重复记录；
- 关键字段空字符串数量为0；

- 无时间逻辑异常记录；
- 无外键孤儿数据。

若校验未通过，需重新排查脏数据，重复“检查-清理-校验”流程，直至数据达标。

5.6 流程闭环

1. 将《脏数据检查记录表》《脏数据清理校验记录表》整理归档，留存处理痕迹，便于后续复盘、交接。
2. 清理达标后，将原始层清洗后的数据写入核心层（带主键、非空等约束），完成数据入层。

6. 处理原则

- 合规性：严格按照本SOP流程执行，不跳过检查、不随意修改清理规则。
- 可追溯：所有检查、清理操作均需记录，包括脚本、执行时间、影响条数、操作人员，确保全程可追溯。
- 数据安全：清理前建议备份原始数据，避免误操作导致数据丢失；清理过程中不修改非脏数据。
- 最小影响：优先删除无法修复的脏数据，不随意修改业务数据，确保清理后数据不偏离源数据核心信息。

7. 异常处理

- 清理过程中出现SQL报错：立即停止清理操作，排查报错原因（如脚本错误、数据格式异常），修正后重新执行，记录报错及解决过程。
- 校验未通过，且无法定位脏数据：重新执行检查脚本，逐行排查异常数据，必要时联系负责人确认清理方案。
- 脏数据数量过大：上报负责人，评估是否需要调整清理规则（如部分数据可修复），避免批量删除影响数据完整性。

8. 附则

- 本SOP自发布之日起生效，所有相关操作人员需严格遵守。
- 本SOP可根据业务需求、数据类型变化，由负责人组织修订，修订后另行通知。
- 本SOP最终解释权归数据处理负责人所有。

附件

附件1：脏数据检查记录表

附件2：脏数据清理校验记录表

(注：文档部分内容可能由 AI 生成)